



Casa abierta al tiempo

UNIVERSIDAD AUTÓNOMA METROPOLITANA
Unidad Iztapalapa

Proyecto Integrador

Taller de Modelado Matemático I

Predicción del precio de cierre de las acciones de Ford mediante técnicas de aprendizaje automático

Ricardo Daniel Moreno Padilla

Matrícula: 2253801126

Profesor: Dr. Juan Alberto Martínez Cadena

Trimestre: 26-P

Fecha: 26 de junio de 2026

1. Introducción

El análisis de series temporales financieras constituye una de las aplicaciones más relevantes del aprendizaje automático debido a la gran cantidad de información generada diariamente por los mercados bursátiles. La posibilidad de utilizar datos históricos para identificar patrones y realizar predicciones ha motivado el desarrollo de numerosos modelos estadísticos y de inteligencia artificial orientados al estudio del comportamiento de los precios de los activos financieros.

Entre las variables utilizadas en el análisis bursátil, el precio de cierre representa uno de los indicadores más importantes, ya que corresponde al último precio negociado durante una jornada de mercado y resume el comportamiento diario de una acción. Debido a ello, el precio de cierre suele emplearse como referencia para el cálculo de indicadores técnicos, medias móviles y estrategias de inversión.

En este proyecto se estudia la evolución histórica del precio de cierre de las acciones de Ford utilizando técnicas de aprendizaje automático supervisado. El objetivo principal consiste en determinar si la información contenida en los precios históricos permite predecir el precio de cierre del día siguiente y, adicionalmente, analizar si es posible anticipar la dirección del movimiento del precio, es decir, si éste aumentará o disminuirá respecto al día actual.

Para ello se desarrollaron dos problemas de aprendizaje diferentes. El primero corresponde a un problema de regresión, cuyo objetivo es estimar el valor del precio de cierre del siguiente día de negociación. El segundo corresponde a un problema de clasificación binaria, en el cual se busca determinar si el precio experimentará un incremento o una disminución respecto al día anterior.

Con el propósito de evaluar el desempeño de distintos enfoques predictivos, se compararon un modelo ingenuo, una regresión lineal, un árbol de decisión y un modelo Random Forest. La evaluación de los modelos se realizó mediante métricas ampliamente utilizadas en aprendizaje automático, tales como MAE y RMSE para regresión, así como Accuracy, Precision, Recall y F1-score para clasificación.

Finalmente, además de comparar el desempeño predictivo de los distintos modelos, se analizó la importancia relativa de las variables utilizadas con el objetivo de identificar cuáles contienen mayor información para describir el comportamiento futuro del precio de cierre.

2. Descripción de los datos

La base de datos utilizada en este proyecto corresponde al comportamiento histórico de las acciones de Ford, obtenida a partir de registros diarios del mercado bursátil. La información comprende el periodo entre septiembre de 2019 y septiembre de 2023 y contiene un total de 1006 observaciones.

Cada registro representa un día de negociación e incluye las siguientes variables:

- Fecha de la operación (**Date**).
- Precio de apertura (**Open**).
- Precio máximo alcanzado durante la jornada (**High**).
- Precio mínimo registrado (**Low**).

- Precio de cierre (**Close**).
- Precio de cierre ajustado (**Adj Close**).

Aunque la base contiene diversas variables financieras, el estudio se centra principalmente en el precio de cierre, ya que éste constituye el indicador más representativo del valor diario de la acción y es la variable empleada como objetivo de predicción.

La elección de esta base de datos se justifica por tratarse de una serie temporal financiera real, suficientemente extensa y con información diaria que permite aplicar técnicas de aprendizaje automático supervisado. Asimismo, representa un caso de estudio adecuado para analizar la capacidad predictiva de distintos modelos sobre un problema de interés económico.

El fenómeno que se desea analizar corresponde a la evolución temporal del precio de cierre de las acciones de Ford y la posibilidad de anticipar su comportamiento futuro utilizando únicamente información histórica. En particular, se busca determinar si los precios observados en días anteriores contienen suficiente información para estimar el precio de cierre del día siguiente o para identificar correctamente si dicho precio aumentará o disminuirá.

Como parte del análisis exploratorio se realizó una inspección inicial de la base de datos, verificando la ausencia de valores faltantes, el tipo de cada variable y el periodo temporal cubierto por los registros. Posteriormente se obtuvieron estadísticas descriptivas y diversas representaciones gráficas que permitieron comprender el comportamiento general de la serie temporal.




Figura 1: Precios de cierre de Ford.

La gráfica temporal permite observar la evolución del precio de cierre durante el periodo de estudio, evidenciando fluctuaciones asociadas a la dinámica propia del mercado bursátil. Se aprecia que la serie presenta periodos de crecimiento y decrecimiento, así como variaciones de distinta magnitud que justifican el empleo de modelos capaces de capturar relaciones temporales.

3. Metodología

El desarrollo del proyecto se llevó a cabo siguiendo las etapas generales de un problema de aprendizaje automático supervisado. En primer lugar, se realizó una inspección de la base de datos con el objetivo de verificar la consistencia de la información, identificar posibles valores faltantes y convertir la variable correspondiente a la fecha al formato adecuado para facilitar el análisis temporal.

Posteriormente se efectuó un análisis exploratorio de los datos mediante estadísticas descriptivas y representaciones gráficas del precio de cierre. Esta etapa permitió conocer el comportamiento general de la serie temporal, identificar tendencias y observar la variabilidad presente durante el periodo de estudio.

Con el propósito de mejorar la capacidad predictiva de los modelos, se realizó un proceso de ingeniería de características. En esta etapa se construyeron nuevas variables derivadas del precio de cierre, las cuales buscan incorporar información histórica del comportamiento reciente de la serie. Las variables consideradas fueron:

- Precio de cierre del día actual.
- Precio de cierre con uno, dos y tres días de rezago.
- Medias móviles de 3, 5 y 10 días.
- Diferencia diaria entre precios consecutivos.
- Rendimiento porcentual diario.

Las variables rezagadas permiten incorporar la dependencia temporal propia de las series financieras, mientras que las medias móviles suavizan las fluctuaciones de corto plazo y permiten representar la tendencia reciente del precio. Por otra parte, la diferencia diaria y el rendimiento porcentual proporcionan información acerca de la magnitud y dirección de los cambios observados entre jornadas consecutivas.

Una vez construidas las variables predictoras, se definieron dos variables objetivo diferentes.

En el problema de regresión, la variable objetivo corresponde al precio de cierre del siguiente día de negociación. De esta forma, el modelo busca estimar el valor futuro del precio utilizando únicamente información disponible hasta el día actual.

En el problema de clasificación se construyó una variable binaria que indica si el precio de cierre del día siguiente es mayor que el precio de cierre actual. En consecuencia, el modelo debe decidir entre dos posibles clases: incremento o disminución del precio.

Después de construir las nuevas variables, se eliminaron aquellas observaciones que contenían valores faltantes generados durante el cálculo de rezagos y medias móviles, obteniendo un conjunto de datos completamente limpio para el entrenamiento de los modelos. Como parte del análisis exploratorio también se calculó la matriz de correlación entre las variables predictoras y la variable objetivo. Esta herramienta permitió identificar el grado de asociación lineal existente entre las distintas características derivadas del precio de cierre.




Figura 2: Matriz de correlación.

La matriz de correlación muestra que los precios recientes y las medias móviles presentan una fuerte correlación positiva con el precio de cierre del día siguiente. Este comportamiento era esperado debido a la naturaleza temporal de la serie, ya que los precios consecutivos suelen mantener una elevada dependencia entre sí. En contraste, las variables correspondientes a la diferencia diaria y al rendimiento porcentual presentan correlaciones más moderadas, aportando información complementaria sobre los cambios recientes del mercado.

Asimismo, se realizó una representación gráfica conjunta del precio de cierre y de las medias móviles construidas durante la ingeniería de características.




Figura 3: Precio de cierre y medias móviles.

Esta representación permite apreciar cómo las medias móviles suavizan las variaciones diarias del precio, facilitando la identificación de tendencias de corto plazo que pueden resultar útiles para los modelos predictivos.

Una vez concluida la etapa de preparación de los datos, el conjunto de observaciones fue dividido en dos subconjuntos: entrenamiento y prueba. Debido a que se trabaja con una serie temporal, no se realizó una selección aleatoria de las observaciones, ya que esto introduciría información del futuro dentro del proceso de entrenamiento. En su lugar, se utilizó una partición cronológica conservando el orden temporal de los datos, destinando aproximadamente el 70 % de las observaciones para entrenamiento y el 30 % restante para la evaluación de los modelos.

Para el problema de regresión se implementaron cuatro modelos diferentes.

El primero corresponde a un modelo ingenuo, el cual supone que el precio de cierre del día siguiente será igual al precio observado en el día actual. Este modelo sirve como línea base para comparar el desempeño de los métodos de aprendizaje automático.

Posteriormente se implementó una regresión lineal múltiple, cuyo objetivo consiste en modelar la relación existente entre las variables predictoras y el precio futuro mediante una combinación lineal de dichas variables.

El tercer modelo corresponde a un árbol de decisión para regresión. Este algoritmo divide recursivamente el espacio de características mediante reglas de decisión, permitiendo capturar relaciones no lineales entre las variables explicativas y la variable objetivo.

Finalmente, se implementó un modelo Random Forest para regresión, el cual construye múltiples árboles de decisión y combina sus predicciones mediante un promedio. Este procedimiento reduce la varianza de las estimaciones y generalmente proporciona una mayor capacidad de generalización.

El desempeño de los modelos de regresión fue evaluado utilizando el Error Absoluto Medio (MAE) y la Raíz del Error Cuadrático Medio (RMSE), métricas ampliamente utilizadas para cuantificar la diferencia entre los valores reales y las predicciones obtenidas.

En el problema de clasificación también se compararon tres modelos distintos.

Se utilizó inicialmente un clasificador ingenuo basado en el comportamiento observado durante la jornada actual, seguido por un árbol de decisión y un modelo Random Forest

para clasificación.

La evaluación de estos modelos se realizó mediante las métricas Accuracy, Precision, Recall y F1-score. Además, para cada clasificador se construyó una matriz de confusión con el objetivo de analizar detalladamente el número de aciertos y errores obtenidos para cada una de las clases.

Finalmente, se calculó la importancia de las variables utilizando el modelo Random Forest. Este análisis permitió identificar cuáles de las características construidas durante la ingeniería de variables aportan mayor información para la predicción del comportamiento futuro del precio de cierre.

“`latex`

4. Resultados y discusión

Una vez entrenados los distintos modelos de aprendizaje automático, se procedió a evaluar su desempeño tanto en el problema de regresión como en el de clasificación. Para ello se utilizaron las métricas descritas en la sección anterior, permitiendo realizar una comparación objetiva entre los diferentes enfoques implementados.

4.1. Resultados del problema de regresión

En el problema de regresión se compararon cuatro modelos: el modelo ingenuo, la regresión lineal, el árbol de decisión y Random Forest. El desempeño de cada uno fue evaluado mediante el Error Absoluto Medio (MAE) y la Raíz del Error Cuadrático Medio (RMSE), donde valores menores indican una mejor capacidad predictiva.

Resultados Regresión			
	Modelo	MAE	RMSE
0	Ingenuo	0.235451	0.323725
1	Regresión Lineal	0.234255	0.322373
2	Árbol	0.274649	0.360859
3	Random Forest	0.261912	0.341691

Figura 4: Comparación de los modelos de regresión.

La tabla anterior resume el desempeño obtenido por cada uno de los modelos considerados. El modelo ingenuo constituye una línea base de comparación, ya que simplemente utiliza el precio de cierre del día actual como predicción para el día siguiente. Los modelos de aprendizaje automático permiten evaluar si la incorporación de información histórica y de variables derivadas proporciona una mejora respecto a esta estrategia sencilla.

En términos generales, se observa que los modelos más sofisticados logran reducir los errores de predicción respecto al modelo ingenuo. Particularmente, el modelo Random Forest aprovecha la combinación de múltiples árboles de decisión para capturar relaciones no lineales presentes en la serie temporal, mientras que la regresión lineal representa únicamente relaciones lineales entre las variables predictoras y la variable objetivo.

Con el propósito de visualizar la calidad de las predicciones obtenidas, se compararon los valores reales del precio de cierre con las estimaciones generadas por el modelo con mejor desempeño.




Figura 5: Mejor modelo de regresión.

La gráfica permite apreciar el grado de coincidencia entre los valores observados y las predicciones realizadas por el modelo. Cuando ambas curvas permanecen próximas entre sí, puede concluirse que el modelo es capaz de reproducir adecuadamente el comportamiento general de la serie temporal. Las diferencias observadas corresponden principalmente a cambios bruscos del mercado, cuya predicción resulta considerablemente más compleja.

4.2. Resultados del problema de clasificación

Para el problema de clasificación se compararon tres modelos: el clasificador ingenuo, un árbol de decisión y un modelo Random Forest. En este caso el objetivo consiste en predecir correctamente si el precio de cierre del día siguiente será mayor o menor que el precio observado en la jornada actual.

El desempeño de los clasificadores fue evaluado mediante las métricas Accuracy, Precision, Recall y F1-score.

	Modelo	Accuracy	Precision	Recall	F1
0	Ingenuo	0.515050	0.540881	0.544304	0.542587
1	Árbol	0.471572	0.000000	0.000000	0.000000
2	Random Forest	0.481605	0.511811	0.411392	0.456140

Figura 6: Modelos de Clasificación

Las métricas anteriores permiten evaluar distintos aspectos del desempeño de cada clasificador. Mientras que la exactitud (Accuracy) mide la proporción total de predicciones

correctas, la precisión (Precision) cuantifica la confiabilidad de las predicciones positivas realizadas por el modelo. Por otra parte, Recall indica la capacidad para identificar correctamente los casos positivos y el F1-score proporciona una medida equilibrada entre precisión y sensibilidad.

Con el propósito de analizar con mayor detalle el comportamiento de cada clasificador, se construyeron las correspondientes matrices de confusión.




Figura 7: Matriz de confusión del modelo ingenuo

La matriz de confusión del modelo ingenuo permite identificar el número de observaciones correctamente clasificadas, así como los errores cometidos al predecir incrementos y disminuciones del precio. Debido a la simplicidad de este modelo, constituye una referencia útil para evaluar las mejoras obtenidas por los algoritmos más complejos.




Figura 8: Matriz de confusión del árbol de decisión.

En el caso del árbol de decisión puede observarse cómo las reglas de partición construidas por el algoritmo permiten mejorar la clasificación respecto al modelo base, aunque su desempeño depende de la complejidad del árbol y de la variabilidad propia de la serie financiera.




Figura 9: Matriz de confusión del Random Forest

La matriz correspondiente al modelo Random Forest permite analizar si la combinación de múltiples árboles logra reducir el número de errores de clasificación. Este comportamiento suele traducirse en una mejora de las métricas de desempeño debido a la reducción de la varianza del modelo.

4.3. Importancia de las variables

Como parte del análisis final se calculó la importancia relativa de las variables predictoras utilizando el modelo Random Forest.




Figura 10: Importancia de variables del Random Forest.

La importancia de variables proporciona información acerca de la contribución de cada característica al proceso de predicción. Las variables con mayor importancia son aquellas que participan con mayor frecuencia en la construcción de los árboles y generan una mayor reducción de la incertidumbre durante el entrenamiento.

En este proyecto resulta esperable que los precios recientes y las medias móviles presenten una contribución significativa, debido a la fuerte dependencia temporal existente entre observaciones consecutivas de una serie financiera. Por otra parte, variables como el rendimiento porcentual y la diferencia diaria complementan la información histórica al describir la magnitud y dirección de los cambios recientes del mercado.

5. Discusión general

Los resultados obtenidos muestran que la ingeniería de características desempeña un papel fundamental en la construcción de modelos predictivos para series temporales financieras. La incorporación de rezagos, medias móviles e indicadores derivados permite representar información histórica relevante que mejora la capacidad predictiva respecto al uso exclusivo del precio de cierre actual.

Asimismo, la comparación entre modelos pone de manifiesto que los algoritmos de aprendizaje automático permiten capturar relaciones más complejas que un modelo ingenuo. No obstante, la naturaleza altamente variable de los mercados financieros limita la posibilidad de realizar predicciones completamente precisas, especialmente durante periodos de elevada volatilidad.

En términos generales, los resultados evidencian que los modelos basados en árboles constituyen una alternativa competitiva para este tipo de problemas, al ser capaces de

modelar relaciones no lineales y aprovechar simultáneamente la información contenida en múltiples variables derivadas de la serie temporal.

6. Conclusiones

En este proyecto se aplicaron distintas técnicas de aprendizaje automático para analizar y predecir el comportamiento del precio de cierre de las acciones de Ford utilizando información histórica del mercado. Los resultados obtenidos muestran que la incorporación de variables derivadas, como los rezagos y las medias móviles, proporciona información relevante para mejorar la capacidad predictiva de los modelos.

La comparación realizada permitió identificar diferencias en el desempeño de los algoritmos implementados. El modelo con mejores resultados fue Random Forest, tanto en el problema de regresión como en el de clasificación, mientras que el modelo ingenuo constituyó una línea base útil para evidenciar las mejoras obtenidas mediante técnicas de aprendizaje automático.

Asimismo, el análisis de importancia de variables mostró que los precios recientes y las características derivadas del comportamiento histórico de la serie aportan la mayor información para realizar predicciones. Esto confirma la fuerte dependencia temporal que caracteriza a las series financieras.

Finalmente, aunque los modelos desarrollados permiten obtener predicciones satisfactorias, la naturaleza dinámica y altamente variable del mercado bursátil impide alcanzar una precisión perfecta. En consecuencia, las técnicas de aprendizaje automático representan una herramienta valiosa para apoyar el análisis financiero, pero sus resultados deben interpretarse como estimaciones sujetas a la incertidumbre inherente al comportamiento del mercado.